


Projeto Conceitual de Software

O projeto Assistente de Voz Residencial consiste em um software em pipeline sequencial orientado a eventos: Wake Word -> STT -> Tradução em Comandos -> Ação -> TTS

Visão Geral do Algoritmo

O sistema opera continuamente "escutando" o que acontece ao seu redor até ouvir a palavra de ativação (Wake Word). A partir disto, este aciona o LED que indica escuta e captura o áudio por até 10 segundos e o salva em arquivo. Este arquivo de audio é então enviado para a nuvem e transformado em texto (STT: Speech To Text). Com o texto do comando obtido em arquivo, novamente este é enviado à nuvem, onde irá acontecer o Processamento Semântico, sendo transformado em comandos a executar. Assim, são executados os comandos e é sintetizado uma resposta em áudio ao usuário (TTS: Text To Speech) e acionado LEDs para indicação de resposta.

Assistente de Voz



Coleta de Dados

O audio é coletado em uma Webcam genérica conectada à porta USB da Raspberry Pi. Este é capturado com uma taxa de amostragem de 16kHz, o que é suficiente para a captura da voz humana, uma vez que estamos seguindo o Teorema da Amostragem de Nyquist-Shannon [1] e é também o suficiente e adequado para reconhecimento de fala.

Processamento de Dados

O processamento de dados ocorre em três fases sequenciais (também já abordadas anteriormente):

1. Detecção da Palavra de Ativação (Local / Wake Word)

- Uma rede neural de detecção de palavra de ativação é executada localmente e continuamente em segundo plano (openWakeWord) para que o comando possa começar a ser gravado assim que detectar uma chamada.

2. Filtragem de Áudio por Energia (RMS) e por Frequência

- O áudio é capturado com um filtro passa faixa que remove ruídos que a frequência estão fora do espectro da fala humana.
- Antes do áudio ser enviado para o processamento semântico, este é primeiro filtrado para que não faça requisições à API do Gemini caso não venha nada após a palavra de ativação. Assim, calcula-se a raiz do valor quadrático médio do sinal de áudio gravado em memória (`numpy.sqrt(numpy.mean(numpy.square(audio))))` e caso o volume do áudio esteja abaixo de um valor de limiar, este é descartado.

3. Processamento Semântico

- Após obter o comando de voz transcrito em texto, é necessário extrair a ação solicitada e traduzir isto em comandos de software. Para isto, será utilizada uma API da LLM Gemini que irá receber o texto do comando de voz e informações adicionais para responder um arquivo em formato JSON contendo os comandos.

O arquivo JSON é estabelecido no seguinte formato:

```
{
  "tipo_comando": types.Schema(
    type=types.Type.STRING,
    enum=[
      "CLIMA",
      "DATA_ATUAL",
      "AGENDAR_TAREFA",
      "LISTAR_TAREFAS",
      "ACIONAR_LAMPADA",
      "ADICIONAR_COMPRAS",
      "LISTAR_COMPRAS",
      "CONVERSA_GERAL"
    ],
    description="A categoria exata da ação que o assistente deve executar."
  ),
  "conteudo": types.Schema(
    type=types.Type.OBJECT,
    description="Parâmetros específicos necessários para executar a ação.",
    properties={
      "estado_lampada": types.Schema(type=types.Type.STRING,
        enum=["ligar", "desligar"]),
      "item_compra": types.Schema(type=types.Type.STRING),
      "descricao_evento": types.Schema(type=types.Type.STRING),
      "data_evento": types.Schema(type=types.Type.STRING),
      "resposta_texto": types.Schema(type=types.Type.STRING,
        description="Resposta em texto para o Piper TTS sintetizar")
    }
  )
}
```

```
}  
)  
}
```

Atuadores

Como atuadores, o sistema possui apenas um autofalante, uma vez que o acionamento da lâmpada será feito por wi-fi. Assim, só será necessário alimentar a caixa de som via USB e conectá-la à saída P2 do Raspberry Pi.

Armazenamento

A lista de compras e agenda serão salvas em arquivos json estruturados, uma vez que devem ser lembradas em cada reinicialização do sistema.

Interface com o usuário

A interface com usuário do sistema será apenas auditiva, com o usuário ditando comandos e o sistema respondendo por áudio, além do acionamento de LEDs indicativos do funcionamento do sistema (aos quais serão explicados no projeto conceitual de hardware).

Inserção do programa no sistema operacional

Para a máxima performance do sistema, serão desativados os seguintes serviços:

- **Bluetooth:** Não serão usados dispositivos bluetooth para captação ou reprodução de áudio
- **cups.service (servidor de impressão):** Não serão usados serviços de impressão.

Para a inserção do programa no sistema operacional, e o programa rode no boot do sistema, será utilizado o systemd pois este gerencia o ciclo de vida do processo monitorando se o programa caiu e reiniciando-o caso necessário.

Referências

[1] MathWorks, "O que é o Teorema de Nyquist?," *MathWorks Discovery*. [Online]. Disponível em: https://www-mathworks-com.translate.goog/discovery/nyquist-theorem.html?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc. [Acesso em: 29-set-2026].